

A ficha que você teria de defender — extração auditável de 19 artigos

Computação Cognitiva · ESPM · 2026.2 · Atividade de Construção I

Integrantes: João Pedro Mascena, Felipe Lira, Felipe Murakami, Pietro Garbin

1. Estratégia de seleção do contexto (4.1)

Escolhida: semantic — trechos selecionados por similaridade dentro do próprio artigo (keyword como alternativa)

Por quê: Cada artigo é segmentado em blocos de 1.200 caracteres (~300 tokens, um parágrafo típico) com sobreposição de 200 (uma frase inteira, para não cortar a evidência); 8 consultas em português, uma ou duas por campo da ficha, recuperam os blocos mais próximos com um embedder multilíngue, reordenados por página. As primeiras páginas quase nunca trazem a limitação declarada e a busca por palavra-chave depende do nome da seção. A escolha é testada na verificação 4.4c (ADR 0002).

estratégia	caracteres_medios	tokens_medios	tokens_corpus
first_pages	10.436	2.428	46.132
keyword	4.950	1.113	21.152
semantic	7.483	1.829	34.749
hybrid	11.562	2.809	53.364

Evidência medida: Das 63 frases em que os autores declaram limitação (15 dos 19 artigos têm ao menos uma), chegaram ao contexto enviado: first_pages 8 (13%; 6/15 artigos), keyword 4 (6%; 4/15 artigos), semantic 9 (14%; 6/15 artigos), hybrid 19 (30%; 9/15 artigos). Só 33% delas estão no último terço do artigo: estão espalhadas, e nenhuma estratégia de orçamento fixo cobre a maioria. O null em limitacao é sobretudo efeito da seleção (o modelo não declara o que não recebe), não da abstenção do modelo. O detector é um regex ruidoso: na revisão manual só ~18 das frases são limitações admitidas pelos autores (precisão ≈ 30%, ADR 0002).

2. Prompt: duas versões e a comparação (4.2)

versão	técnicas	descrição
v_full	papel, delimitadores, few-shot (com caso null), abstenção	Versão de referência.
v_sem_fewshot	papel, delimitadores, abstenção	Difere da referência em uma técnica.

O que muda: v_full × v_sem_fewshot: few_shot: on → off

métrica	v_full	v_sem_fewshot
JSON válido de primeira	100%	100%
parse falhou (sem ficha)	0%	0%
null correto quando não há limitação	100%	100%
trecho encontrado (fidelidade)	95%	79%
página correta	84%	53%
fichas idênticas entre versões	0%	0%
tokens de entrada	73.614	57.198

O que a comparação mostrou: v_full vence por rate_fidelity: 0.947 (v_full) vs 0.789 (v_sem_fewshot); critérios anteriores empataram. Discordam em 101 campo(s): dados, evidencia.pagina, evidencia.trecho, limitacao, metodo, metrica, problema. Versão final: v_full.

3. Modelo e temperatura (4.2-4.3)

Modelo: Qwen/Qwen2.5-3B-Instruct. Qwen2.5-3B-Instruct cabe na T4 gratuita em meia precisão (~6 GB + contexto) e é o equilíbrio recomendado: o 1,5B erra demais nesta tarefa e o 7B exige 4 bits. Erros do modelo pequeno são matéria-prima da auditoria, não impedimento.

Temperatura: Extração é tarefa de fidelidade, não de criatividade: queremos a saída mais provável e reproduzível entre execuções (seed fixa). A verificação 4.4d mede o que muda com uma temperatura mais alta.

4. Auditoria: as quatro verificações (4.4)

a) Fidelidade. 1/19 trecho(s) inventado(s), ausente(s) do texto enviado: 08_Leka_2019 (cópia do exemplo few-shot do prompt). Página errada em 2/19 (11_Jarolim_2023: declarada 15, encontrada 16; D04_Jiao_2020: declarada 18, encontrada 15): trecho real, mas a ficha não é rastreável como declarada — BAIXA.

trecho encontrado: 18/19 (95%) · **página correta:** 16/19 · **exato / aproximado / sem ficha:** 17 / 2 / 0

Invenção convincente — 08_Leka_2019: o modelo devolveu como evidência «Forecast accuracy is measured with the weighted mean absolute percentage error (WMAPE) over a 13-week horizon.», a frase do EXEMPLO few-shot do prompt, ausente do artigo. Detectado porque a fidelidade compara o trecho com o texto efetivamente enviado ao modelo, e o exemplo não faz parte dele (similaridade 0,47 < limiar 0,90). O JSON era válido de primeira e a página declarada, plausível: nenhuma checagem de formato o pegaria. A ficha foi rebaixada a BAIXA.

b) Estabilidade. 19/19 fichas idênticas nas duas execuções — esperado com decodificação gulosa e seed fixa. Por isso a variabilidade real do pipeline aparece no efeito da entrada (c) e da temperatura (d), não aqui.

pares comparados: 19 · **fichas idênticas:** 19/19 (100%) · **campos que mais mudam:** nenhum

c) Efeito da entrada. Defendemos semantic: semantic vence por maior taxa de página correta (0.842 vs 0.684). Sem gabarito manual não dá para separar abstenção correta de omissão; a heurística de vocabulário de limitação teve falsos positivos confirmados (título 'Scope, and Limitations'; parágrafo sobre limitações da IA generativa) e por isso não entra na regra.

estratégias: semantic × first_pages · **fichas idênticas:** 0/19 · **divergências substantivas:** 103 · **fidelidade:** semantic 95% · first_pages 95% · **campos que mais divergem:** problema 100%, metodo 95%, dados 89% · **limitacao null:** semantic 18/19 · first_pages 19/19

d) Efeito da temperatura. Pelo critério declarado, t=0,0 não se sustenta neste subconjunto: t=0,7 teve fidelidade 100% vs 83% em t=0,0. Erro(s) em t=0,0: 08_Leka_2019 (vazamento do exemplo few-shot). Com n=6 artigos, a diferença não sustenta conclusão. Mantemos t=0,0 pela estabilidade (19/19 fichas idênticas entre repetições) e reportamos o resultado como está.

subconjunto: 6 artigos · **JSON válido de primeira:** t=0,0: 100% · t=0,7: 100% · **fidelidade:** t=0,0: 83% · t=0,7: 100% · **fichas idênticas:** 0/6

Regra de confiança (declarada): Regra de confiança v2 (aplicada automaticamente; o nível final é o MENOR entre os limites abaixo):

- BAIXA se a extração falhou (nenhum JSON válido segundo o esquema), ou o trecho de evidência não foi encontrado no texto enviado ao modelo (similaridade partial_ratio normalizada < 0.90), ou o trecho foi encontrado numa página diferente da declarada em evidencia.pagina, ou mais de 2 campos mudaram entre as duas repetições (mesma entrada).

- MEDIA se a evidência passou, mas entre 1 e 2 campos mudaram entre as repetições, ou limitacao é null numa estratégia de entrada e preenchida na outra (discordância categórica), ou se alguma comparação não pôde ser feita (ausente ou sem ficha válida do outro lado): o que não foi verificado não recebe ALTA.

- No máximo MEDIA se o campo limitacao veio preenchido mas o texto enviado não contém nenhum termo de limitação (limitation, shortcoming, drawback, caveat, future work, threats to validity...), sinal de limitação possivelmente inventada. O caso inverso (limitacao null com a palavra 'limitation' no contexto) NÃO rebaixa: a heurística teve falsos positivos (títulos de seção e uso genérico da palavra).


- ALTA somente se a evidência foi encontrada na página declarada e no máximo 0 campo(s) mudou(aram) entre repetições e não há discordância categórica entre estratégias.

Campos comparados: problema, dados, metodo, metrica, limitacao, evidencia.trecho, evidencia.pagina; textos iguais após normalização tipográfica (NFKC, minúsculas, espaços, aspas e hífens).

Modo de comparação entre estratégias: categorical (v2) — entre estratégias só conta como mudança a discordância categórica em limitacao (null de um lado, texto do outro); paráfrase de texto livre e evidência de outra página não contam. Entre repetições (mesma entrada) a comparação continua exata.

Distribuição resultante: alta 15, média 1, baixa 3.

Calibração da regra — v1 estrita: alta 0/média 2/baixa 17; v2 categórica (final): alta 15/média 1/baixa 3. A similaridade média dos campos de texto livre é 0,48 entre estratégias (paráfrase de entradas diferentes) e 1,00 entre repetições: comparar o texto exato entre estratégias mede redação, não confiabilidade. Por isso a regra final só conta discordância categórica entre estratégias (limitação declarada × null).



5. Fichas que não defenderíamos

arquivo	motivos
08_Leka_2019_Comparison_Flare_Forecasting_III_Systematic_Behavior s.pdf	trecho não encontrado no texto enviado (score 0.47 < 0.90): possível trecho inventado
11_Jarolim_2023_Coronal_Field_PINN.pdf	página errada: declarada p. 15, trecho localizado em p. 16
D04_Jiao_2020_Flare_Intensity_Prediction_ML.pdf	página errada: declarada p. 18, trecho localizado em p. 15

6. Custo (4.5)

Premissa: US\$ 3.00 por 1M tokens de entrada e US\$ 15.00 por 1M tokens de saída (fonte: Tabela pública Anthropic, Claude Sonnet 4.5, consultada em 2026-09).

cenário	chamadas	tokens entrada	tokens saída	US\$
20260923-144026_semantic_v_full_t0.0_rep1	19	73.614	4.598	0,2898
20260923-145329_semantic_v_full_t0.0_rep2	19	73.614	4.598	0,2898
20260923-150455_semantic_v_sem_fewshot_t0.0_rep1	19	57.198	5.382	0,2523
20260923-151736_first_pages_v_full_t0.0_rep1	19	84.997	4.739	0,3261
20260923-152920_semantic_v_full_t0.7_rep1	6	21.620	1.502	0,0874
TOTAL real (todas as execuções)	82	311.043	20.819	1,2454
ingênuo (artigo inteiro, mesmas chamadas)	82	1.822.496	20.819	5,7798

Razão ingênuo/real: a alternativa ingênua custa 4,60× a real.

Tokens de entrada: a alternativa ingênua envia 5.9× mais. Repetições de estabilidade, a outra estratégia, a outra temperatura e a outra versão do prompt estão incluídas no total real.

7. O que faríamos diferente com mais uma semana

- Anotar à mão um gabarito de limitacao em 5 artigos, para separar abstenção correta de omissão (hoje indistinguíveis).
- Instruir explicitamente "não copie os exemplos" no prompt e medir se o vazamento do few-shot para a evidência desaparece.
- Comparar o modelo local com um modelo por API nas mesmas 19 fichas.

8. Declaração de uso de IA

Usamos assistentes de IA para escrever partes do código e revisar textos. As decisões de projeto, os números e as conclusões foram verificados pelo grupo, que sabe explicar cada linha do código entregue.