

A ficha que você teria de defender — extração auditável de 19 artigos

Computação Cognitiva · ESPM · 2026.2 · Atividade de Construção I

Integrantes: João Pedro Mascena, Felipe Lira, Felipe Murakami, Pietro Garbin

1. Estratégia de seleção do contexto (4.1)

Escolhida: semantic — trechos selecionados por similaridade dentro do próprio artigo (keyword como alternativa)

Por quê: Cada artigo é segmentado em blocos de 1.200 caracteres (~300 tokens, um parágrafo típico) com sobreposição de 200 (uma frase inteira, para não cortar a evidência); 8 consultas em português, uma ou duas por campo da ficha, recuperam os blocos mais próximos com um embedder multilíngue, reordenados por página. As primeiras páginas quase nunca trazem a limitação declarada e a busca por palavra-chave depende do nome da seção. A escolha é testada na verificação 4.4c (ADR 0002).

estratégia	caracteres_medios	tokens_medios	tokens_corpus
first_pages	10.436	2.428	46.132
keyword	4.248	955	18.143
semantic	7.483	1.829	34.749

2. Prompt: duas versões e a comparação (4.2)

versão	técnicas	descrição
v_full	papel, delimitadores, few-shot (com caso null), abstenção	Versão de referência.
v_sem_fewshot	papel, delimitadores, abstenção	Difere da referência em uma técnica.

O que muda: v_full × v_sem_fewshot: few_shot: on → off

métrica	v_full	v_sem_fewshot
JSON válido de primeira	100%	100%
parse falhou (sem ficha)	0%	0%
null correto quando não há limitação	100%	100%
trecho encontrado (fidelidade)	95%	79%
página correta	84%	53%
fichas idênticas entre versões	0%	0%
tokens de entrada	73.614	57.198

O que a comparação mostrou: v_full vence por rate_fidelity: 0.947 (v_full) vs 0.789 (v_sem_fewshot); critérios anteriores empataram. Discordam em 101 campo(s): dados, evidencia.pagina, evidencia.trecho, limitacao, metodo, metrica, problema. Versão final: v_full.

3. Modelo e temperatura (4.2-4.3)

Modelo: Qwen/Qwen2.5-3B-Instruct. Qwen2.5-3B-Instruct cabe na T4 gratuita em meia precisão (~6 GB + contexto) e é o equilíbrio recomendado: o 1,5B erra demais nesta tarefa e o 7B exige 4 bits. Erros do modelo pequeno são matéria-prima da auditoria, não impedimento.

Temperatura: Extração é tarefa de fidelidade, não de criatividade: queremos a saída mais provável e reproduzível entre execuções (seed fixa). A verificação 4.4d mede o que muda com uma temperatura mais alta.

4. Auditoria: as quatro verificações (4.4)

a) Fidelidade. 1 de 19 trechos não existem no texto enviado — tratados como inventados:

08_Leka_2019_Comparison_Flare_Forecasting_III_Systematic_Behaviors.pdf.

trecho encontrado: 18/19 (95%) · **página correta:** 16/19 · **exato / aproximado / sem ficha:** 17 / 2 / 0

b) Estabilidade. As 19 fichas foram idênticas nas duas execuções.

pares comparados: 19 · **fichas idênticas:** 19/19 (100%) · **campos que mais mudam:** nenhum

c) Efeito da entrada. Defendemos semantic: semantic vence por maior taxa de página correta (0.842 vs 0.684).

estratégias: semantic × first_pages · **fichas idênticas:** 0/19 · **divergências substantivas:** 103 · **fidelidade:** semantic 95% · first_pages 95% · **campos que mais divergem:** problema 100%, metodo 95%, dados 89%

d) Efeito da temperatura. A escolha de t=0,0 NÃO se sustenta pelo critério declarado: t=0,7 teve validade ou fidelidade maior neste subconjunto — reportado como está.

subconjunto: 6 artigos · **JSON válido de primeira:** t=0,0: 100% · t=0,7: 100% · **fidelidade:** t=0,0: 83% · t=0,7: 100% · **fichas idênticas:** 0/6

Regra de confiança (declarada): Regra de confiança (aplicada automaticamente; o nível final é o MENOR entre os limites abaixo):

- BAIXA se a extração falhou (nenhum JSON válido segundo o esquema), ou o trecho de evidência não foi encontrado no texto enviado ao modelo (similaridade parcial_ratio normalizada < 0.90), ou o trecho foi encontrado numa página diferente da declarada em evidencia.pagina; ou mais de 2 campos mudaram entre as duas repetições ou entre as duas estratégias de entrada.


- MEDIA se a evidência passou, mas entre 1 e 2 campos mudaram em alguma das comparações (repetição ou estratégia), ou se alguma comparação não pôde ser feita (ausente ou sem ficha válida do outro lado): o que não foi verificado não recebe ALTA.

- No máximo MEDIA se o campo limitacao veio preenchido mas o texto enviado não contém nenhum termo de limitação (limitation, shortcoming, drawback, caveat, future work, threats to validity...), sinal de limitação possivelmente inventada.

- ALTA somente se a evidência foi encontrada na página declarada e no máximo 0 campo(s) mudou(aram) tanto entre repetições quanto entre estratégias.

Campos comparados: problema, dados, metodo, metrica, limitacao, evidencia.trecho, evidencia.pagina; textos iguais após

normalização tipográfica (NFKC, minúsculas, espaços, aspas e hífen).
Distribuição resultante: alta 0, média 2, baixa 17.



5. Fichas que não defenderíamos

arquivo	motivos
03_Camporeale_Berger_2025_Verification_NOAA_SWPC_Flare_Forecast.pdf	6 campos mudaram entre estratégias de entrada (instável)
06_Barnes_2016_Comparison_Flare_Forecasting_I_AllClear.pdf	4 campos mudaram entre estratégias de entrada (instável)
07_Leka_2019_Comparison_Flare_Forecasting_II_Benchmarks.pdf	6 campos mudaram entre estratégias de entrada (instável)
08_Leka_2019_Comparison_Flare_Forecasting_III_Systematic_Behaviors.pdf	trecho não encontrado no texto enviado (score 0.47 < 0.90): possível trecho inventado; 6 campos mudaram entre estratégias de entrada (instável)
09_AsensioRamos_2023_ML_in_Solar_Physics.pdf	6 campos mudaram entre estratégias de entrada (instável)
11_Jarolim_2023_Coronal_Field_PINN.pdf	página errada: declarada p. 15, trecho localizado em p. 16; 6 campos mudaram entre estratégias de entrada (instável)
13_Camporeale_2020_GrayBox_Regional_Ground_Magnetic_Perturbations.pdf	6 campos mudaram entre estratégias de entrada (instável)
14_Licata_Mehta_2022_UQ_DataDriven_Space_Weather.pdf	6 campos mudaram entre estratégias de entrada (instável)
15_Guastavino_2022_Implementation_Paradigm_Flare_Forecasting.pdf	6 campos mudaram entre estratégias de entrada (instável)
16_Nishizuka_2020_Deep_Flare_Net_Reliable.pdf	6 campos mudaram entre estratégias de entrada (instável)
17a_Roy_2025_Surya_Foundation_Model_Heliophysics.pdf	6 campos mudaram entre estratégias de entrada (instável)
17b_Roy_2025_SuryaBench.pdf	6 campos mudaram entre estratégias de entrada (instável)
18_Karniadakis_2021_Physics_Informed_ML.pdf	7 campos mudaram entre estratégias de entrada (instável)
D01_Li_2020_Predicting_Flares_Deep_CNN.pdf	6 campos mudaram entre estratégias de entrada (instável)
D02_Wang_2020_Predicting_Flares_ML_Solar_Cycle_Dependence.pdf	5 campos mudaram entre estratégias de entrada (instável)
D03_Sun_2022_Predicting_Flares_CNN_LSTM_Two_Solar_Cycles.pdf	6 campos mudaram entre estratégias de entrada (instável)
D04_Jiao_2020_Flare_Intensity_Prediction_ML.pdf	página errada: declarada p. 18, trecho localizado em p. 15; 6 campos mudaram entre estratégias de entrada (instável)

6. Custo (4.5)

Premissa: US\$ 3.00 por 1M tokens de entrada e US\$ 15.00 por 1M tokens de saída (fonte: Tabela pública Anthropic, Claude Sonnet 4.5, consultada em 2026-09).

cenário	chamadas	tokens entrada	tokens saída	US\$
20260923-144026_semantic_v_full_t0.0_rep1	19	73.614	4.598	0,2898
20260923-145329_semantic_v_full_t0.0_rep2	19	73.614	4.598	0,2898
20260923-150455_semantic_v_sem_fewshot_t0.0_rep1	19	57.198	5.382	0,2523
20260923-151736_first_pages_v_full_t0.0_rep1	19	84.997	4.739	0,3261
20260923-152920_semantic_v_full_t0.7_rep1	6	21.620	1.502	0,0874
TOTAL real (todas as execuções)	82	311.043	20.819	1,2454
ingênuo (artigo inteiro, mesmas chamadas)	82	1.822.496	20.819	5,7798

Razão ingênuo/real: a alternativa ingênua custa 4,60x a real.

Tokens de entrada: a alternativa ingênua envia 5.9x mais. Repetições de estabilidade, a outra estratégia, a outra temperatura e a outra versão do prompt estão incluídas no total real.

7. O que faríamos diferente com mais uma semana

- Anotar à mão um gabarito de alguns artigos para medir acurácia, não só consistência e fidelidade.
- Comparar o modelo local com um modelo por API nas mesmas 19 fichas.
- Testar a variante com raciocínio em campo separado (v_cot) e medir se compensa.

8. Declaração de uso de IA

Usamos assistentes de IA para escrever partes do código e revisar textos. As decisões de projeto, os números e as conclusões foram verificados pelo grupo, que sabe explicar cada linha do código entregue.