

A ficha que você teria de defender — extração auditável de 19 artigos

Computação Cognitiva · ESPM · 2026.2 · Atividade de Construção I

Integrantes: João Pedro Mascena, Felipe Lira, Felipe Murakami, Pietro Garbin

1. Estratégia de seleção do contexto (4.1)

Escolhida: semantic — blocos por similaridade dentro do próprio artigo (first_pages como alternativa da 4.4c; hybrid testado como experimento e descartado)

Por quê: Blocos de 1.200 caracteres (~300 tokens, um parágrafo típico) com sobreposição de 200 (uma frase inteira, para não cortar a evidência); 8 consultas em português, uma ou duas por campo, embedder multilíngue, blocos reordenados por página. Como limitacao veio null em quase todas as fichas, testamos o hybrid, que prioriza janelas de limitação: Corrigimos a entrada — artigos com limitação declarada no contexto: 6 → 9 de 15; recall das frases 14% → 30%. E a saída não mudou: limitacao legítima 1/19 (18_Karniadakis_2021) × 0/19 (—); no hybrid (experimento), 2 preenchida(s) copiada(s) do exemplo e 0 sentinela. O gargalo de limitacao é o modelo, não a seleção; o próximo passo é um modelo maior (ou API) ou uma segunda passagem dedicada só a limitação. Pelo critério declarado da 4.4c (pagina correta: 16/19 × 14/19; tokens de entrada +25% no hybrid (experimento)), a estratégia final é semantic.

estrategia	caracteres_medios	tokens_medios	tokens_corpus
first_pages	10.436	2.428	46.132
keyword	4.950	1.113	21.152
semantic	7.483	1.829	34.749
hybrid	11.562	2.809	53.364

Evidência medida: Das 63 frases em que os autores declaram limitação (15 dos 19 artigos têm ao menos uma), chegaram ao contexto enviado: first_pages 8 (13%; 6/15 artigos), keyword 4 (6%; 4/15 artigos), semantic 9 (14%; 6/15 artigos), hybrid 19 (30%; 9/15 artigos). Só 33% delas estão no último terço do artigo: estão espalhadas, e nenhuma estratégia de orçamento fixo cobre a maioria. O null em limitacao é sobretudo efeito da seleção (o modelo não declara o que não recebe), não da abstenção do modelo. O detector é um regex ruidoso: na revisão manual só ~18 das frases são limitações admitidas pelos autores (precisão ≈ 30%, ADR 0002). Curva de orçamento do hybrid (recall das frases; artigos; tokens/artigo) — 12k: 30%, 9/15 artigos, ~2.861 tok · 16k: 33%, 11/15 artigos, ~3.724 tok · 20k: 44%, 15/15 artigos, ~4.475 tok · sem teto: 51%, 15/15 artigos, ~5.481 tok. Escolhemos 12k por custo: 6,6× mais barato que o artigo inteiro e +54% de caracteres sobre o semantic. 20k fica documentado como alternativa (15/15 artigos, +56% de tokens). Ressalva: as pistas de seleção e o regex de medição compartilham cinco termos; nas frases sem pista, as pistas não ajudam com 12k — o ganho real está nas limitações explícitas revisadas à mão (ADR 0002).

2. Prompt: duas versões e a comparação (4.2)

versão	técnicas	descrição
v_full	papel, delimitadores, few-shot (com caso null), abstenção	Versão de referência.
v_sem_fewshot	papel, delimitadores, abstenção	Difere da referência em uma técnica.

O que muda: v_full × v_sem_fewshot: few_shot: on → off

métrica	v_full	v_sem_fewshot
JSON válido de primeira	100%	100%
parse falhou (sem ficha)	0%	0%
null correto quando não há limitação	100%	100%
trecho encontrado (fidelidade)	95%	79%
página correta	84%	53%
vazamento de exemplos	11%	0%
fichas idênticas entre versões	0%	0%
tokens de entrada	73.614	57.198

O que a comparação mostrou: v_full vence por rate_fidelity: 0.947 (v_full) vs 0.789 (v_sem_fewshot); critérios anteriores empataram. Discordam em 101 campo(s): dados, evidencia.pagina, evidencia.trecho, limitacao, metodo, metrica, problema. Versão final: v_full. Trade-off: v_full tem fidelidade 95% × 79%, mas 11% das fichas copiam campos do exemplo (× 0% em v_sem_fewshot); o critério de vitória declarado não muda.

3. Modelo e temperatura (4.2-4.3)

Modelo: Qwen/Qwen2.5-3B-Instruct. Qwen2.5-3B-Instruct cabe na T4 gratuita em meia precisão (~6 GB + contexto) e é o equilíbrio recomendado a 1,5B erra demais nesta tarefa e o 7B exige 4 bits. Erros do modelo pequeno são matéria-prima da auditoria, não impedimento.

Temperatura: Extração é tarefa de fidelidade, não de criatividade: queremos a saída mais provável e reproduzível entre execuções (seed fixa). A verificação 4.4d mede o que muda com uma temperatura mais alta.

4. Auditoria: as quatro verificações (4.4)

a) Fidelidade. 1/19 trecho(s) inventado(s), ausente(s) do texto enviado: 08_Leka_2019 (cópia do exemplo few-shot do prompt). Página errada em 2/19 (11_Jarolim_2023: declarada 15, encontrada 16; D04_Jiao_2020: declarada 18, encontrada 15); trecho real, mas a ficha não é rastreável como declarada — BAIXA.

trecho encontrado: 18/19 (95%) · **página correta:** 16/19 · **exato / aproximado / sem ficha:** 17 / 2 / 0

Invenções convincentes detectadas — (1) 08_Leka_2019, execução semantic (principal): o modelo copiou do exemplo few-shot do prompt os campos dados, metodo, metrica e o trecho «Forecast accuracy is measured with the weighted mean absolute percentage error (WMAPE) over a 13-week horizon.», ausente do artigo. Detectado pela fidelidade, que compara o trecho com o texto enviado — do qual o exemplo não faz parte. (2) 06_Barnes_2016, execução hybrid (experimento): o campo limitacao «Os rótulos vêm de chargebacks, então

fraudes nunca contestadas pelos clientes ficam fora da verdade de referê...» foi copiado do exemplo few-shot, com trecho de evidência correto — fidelidade e página passam. Só a comparação dos campos com os exemplos do prompt detecta. JSON válido de primeira: nenhuma checagem de formato os pegaria. Outros 5 caso(s) nas tabelas das verificações a) e e).

b) Estabilidade. 19/19 fichas idênticas nas duas execuções — esperado com decodificação gulosa e seed fixa. Por isso a variabilidade real do pipeline aparece no efeito da entrada (c) e da temperatura (d), não aqui.

pares comparados: 19 · **fichas idênticas:** 19/19 (100%) · **campos que mais mudam:** nenhum

c) Efeito da entrada. Defendemos semantic: semantic vence por maior taxa de página correta (0.842 vs 0.684). Experimento hybrid × semantic: comparação a três na seção 1. Sem gabarito manual não dá para separar abstenção correta de omissão; a heurística de vocabulário de limitação teve falsos positivos confirmados (título 'Scope, and Limitations'; parágrafo sobre limitações da IA generativa) e por isso não entra na regra.

estratégias: semantic × first_pages · **fichas idênticas:** 0/19 · **divergências substantivas:** 103 · **fidelidade:** semantic 95% · first_pages 95% · **campos que mais divergem:** problema 100%, metodo 95%, dados 89% · **limitacao null:** semantic 18/19 · first_pages 19/19

d) Efeito da temperatura. Pelo critério declarado, t=0,0 não se sustenta neste subconjunto: t=0,7 teve fidelidade 100% vs 83% em t=0,0. Erro(s) em t=0,0: 08_Leka_2019 (vazamento do exemplo few-shot). Com n=6 artigos, a diferença não sustenta conclusão. Mantemos t=0,0 pela estabilidade (19/19 fichas idênticas entre repetições) e reportamos o resultado como está.

subconjunto: 6 artigos · **JSON válido de primeira:** t=0,0: 100% · t=0,7: 100% · **fidelidade:** t=0,0: 83% · t=0,7: 100% · **fichas idênticas:** 0/6

e) Vazamento de exemplos few-shot. Cópias do exemplo aparecem mesmo com exemplos em domínio propositalmente distante; a verificação compara cada campo com o campo homólogo dos exemplos (limiar 0,80).

semantic (principal): 2/19 (dados, metodo, metrica, evidencia.trecho) · **hybrid (experimento):** 2/19 (limitacao, evidencia.trecho) · **v_sem_fewshot:** 0/19

Regra de confiança (declarada): Regra de confiança v2 (aplicada automaticamente; o nível final é o MENOR entre os limites abaixo):

- BAIXA se a extração falhou (nenhum JSON válido segundo o esquema), ou o trecho de evidência não foi encontrado no texto enviado ao modelo (similaridade parcial_ratio normalizada < 0.90), ou o trecho foi encontrado numa página diferente da declarada em evidencia.pagina, ou algum campo textual (problema, dados, metodo, metrica, limitacao, evidencia.trecho) reproduz o campo homólogo de um exemplo few-shot do prompt (similaridade ≥ 0.80; trecho também contra o texto do exemplo), ou algum campo contém um termo de domínio exclusivo dos exemplos (fraude, chargeback, supermercados, vendas, WMAPE, suavização exponencial...) cujo equivalente em inglês não aparece no texto enviado — cópia do exemplo é invenção, mesmo quando o trecho passa na fidelidade, ou mais de 2 campos mudaram entre as duas repetições (mesma entrada).

- MEDIA se a evidência passou, mas entre 1 e 2 campos mudaram entre as repetições, ou limitacao é null numa estratégia de entrada e preenchida na outra (discordância categórica), ou se alguma comparação não pôde ser feita (ausente ou sem ficha válida do outro lado): o que não foi verificado não recebe ALTA.

- No máximo MEDIA se o campo limitacao veio preenchido mas o texto enviado não contém nenhum termo de limitação (limitation, shortcoming, drawback, caveat, future work, threats to validity...), sinal de limitação possivelmente inventada. O caso inverso (limitacao null com a palavra 'limitation' no contexto) NÃO rebaixa: a heurística teve falsos positivos (títulos de seção e uso genérico da palavra).


- ALTA somente se a evidência foi encontrada na página declarada e no máximo 0 campo(s) mudou(aram) entre repetições e não há discordância categórica entre estratégias.

Campos comparados: problema, dados, metodo, metrica, limitacao, evidencia.trecho, evidencia.pagina; textos iguais após normalização tipográfica (NFKC, minúsculas, espaços, aspas e hífen).

Modo de comparação entre estratégias: categorical (v2) — entre estratégias só conta como mudança a discordância categórica em limitacao (null de um lado, texto do outro); paráfrase de texto livre e evidência de outra página não contam. Entre repetições (mesma entrada) a comparação continua exata.

Distribuição resultante: alta 14, média 1, baixa 4.

Calibração da regra — v1 estrita: alta 0/média 2/baixa 17; v2 categórica (final): alta 14/média 1/baixa 4. A similaridade média dos campos de texto livre é 0,48 entre estratégias (paráfrase de entradas diferentes) e 1,00 entre repetições: comparar o texto exato entre estratégias mede redação, não confiabilidade. Por isso a regra final só conta discordância categórica entre estratégias (limitação declarada × null).



5. Fichas que não defenderíamos

arquivo	motivos
08_Leka_2019_Comparison_Flare_Forecasting_III_Systematic_Behavior s.pdf	campo dados copiado do exemplo few-shot (similaridade 0.97); campo metodo copiado do exemplo few-shot (similaridade 1.00); campo metrica copiado do exemplo few-shot (similaridade 1.00); campo evidencia.trecho copiado do exemplo few-shot (similaridade 1.00); campo dados contém 'supermercados', 'vendas', termos do exemplo few-shot ausentes do texto enviado; campo metodo contém 'promoções', 'feriados', termos do exemplo few-shot ausentes do texto enviado; campo metrica contém 'WMAPE', 'suavização exponencial', termos do exemplo few-shot ausentes do texto enviado; campo evidencia.trecho contém 'WMAPE', termo do exemplo few-shot ausente do texto enviado; trecho não encontrado no texto enviado (score 0.47 < 0.90): possível trecho inventado
09_AsenioRamos_2023_ML_in_Solar_Physics.pdf	campo dados contém 'supermercados', termo do exemplo few-shot ausente do texto enviado
11_Jarolim_2023_Coronal_Field_PINN.pdf	página errada: declarada p. 15, trecho localizado em p. 16
D04_Jiao_2020_Flare_Intensity_Prediction_ML.pdf	página errada: declarada p. 18, trecho localizado em p. 15

6. Custo (4.5)

Premissa: US\$ 3.00 por 1M tokens de entrada e US\$ 15.00 por 1M tokens de saída (fonte: Tabela pública Anthropic, Claude Sonnet 4.5, consultada em 2026-09).

cenário	chamadas	tokens entrada	tokens saída	US\$
20260923-144026_semantic_v_full_t0.0_rep1	19	73.614	4.598	0,2898
20260923-145329_semantic_v_full_t0.0_rep2	19	73.614	4.598	0,2898
20260923-150455_semantic_v_sem_fewshot_t0.0_rep1	19	57.198	5.382	0,2523
20260923-151736_first_pages_v_full_t0.0_rep1	19	84.997	4.739	0,3261
20260923-152920_semantic_v_full_t0.7_rep1	6	21.620	1.502	0,0874
20260923-154759_hybrid_v_full_t0.0_rep1	19	92.229	4.628	0,3461
20260923-155849_hybrid_v_full_t0.0_rep2	16	77.015	3.776	0,2877
TOTAL real (todas as execuções)	117	480.287	29.223	1,8792
ingênuo (artigo inteiro, mesmas chamadas)	117	2.612.853	29.223	8,2769

Razão ingênuo/real: a alternativa ingênua custa 4,40x a real.

Tokens de entrada: a alternativa ingênua envia 5.4x mais. O total real inclui tudo o que foi enviado: repetição de estabilidade, outra estratégia, outra temperatura, outra versão do prompt e os experimentos de seleção (execuções hybrid).

7. O que faríamos diferente com mais uma semana

- Uma segunda passagem dedicada só a limitacao, sobre as janelas de pista de limitação (a entrada já as traz; o modelo de 3B não as usa na ficha completa).
- Modelo maior — Qwen2.5-7B em 4 bits ou um modelo por API — nas mesmas 19 fichas.
- Instrução explícita "não copie os exemplos" e medir se o vazamento do few-shot some; exemplos em domínio distante não bastaram.
- Gabarito manual de limitacao em 5 artigos, para separar abstenção de omissão.

8. Declaração de uso de IA

Usamos assistentes de IA para escrever partes do código e revisar textos. As decisões de projeto, os números e as conclusões foram verificados pelo grupo, que sabe explicar cada linha do código entregue.