

Atividade de Construção I — Ficha comparativa de 19 artigos

Computação Cognitiva · Ciência de Dados e Negócios · ESPM · 2026.2 · Prof. André Insardi

Integrantes: João Pedro Mascena, Felipe Lira, Felipe Murakami, Pietro Garbin

1. Estratégia de seleção do contexto (4.1)

Escolhida: semantic — blocos por similaridade dentro do próprio artigo (first_pages como alternativa da 4.4c; hybrid testado como experimento e descartado)

Por quê: Blocos de 1.200 caracteres (~300 tokens, um parágrafo típico) com sobreposição de 200 (uma frase inteira, para não cortar a evidência); 8 consultas em português, uma ou duas por campo, embedder multilíngue, blocos reordenados por página. Como limitacao veio null em quase todas as fichas, testamos o hybrid, que prioriza janelas de limitação: Corrigimos a entrada — artigos com limitação declarada no contexto: 6 → 9 de 15; recall das frases 14% → 30%. E a saída não mudou: limitacao legítima 1/19 (18_Karniadakis_2021) × 0/19 (—); no hybrid (experimento), 2 preenchida(s) copiada(s) do exemplo e 0 sentinela. O gargalo de limitacao é o modelo, não a seleção; o próximo passo é um modelo maior (ou API) ou uma segunda passagem dedicada só a limitação. Pelo critério declarado da 4.4c (pagina correta: 16/19 × 14/19; tokens de entrada +25% no hybrid (experimento)), a estratégia final é semantic.

estrategia	caracteres_medios	tokens_medios	tokens_corpus
first_pages	10.436	2.428	46.132
keyword	4.950	1.113	21.152
semantic	7.483	1.829	34.749
hybrid	11.562	2.809	53.364

Evidência medida: Das 63 frases em que os autores declaram limitação (15 dos 19 artigos têm ao menos uma), chegaram ao contexto enviado: first_pages 8 (13%; 6/15 artigos), keyword 4 (6%; 4/15 artigos), semantic 9 (14%; 6/15 artigos), hybrid 19 (30%; 9/15 artigos). Só 33% delas estão no último terço do artigo: estão espalhadas, e nenhuma estratégia de orçamento fixo cobre a maioria. O null em limitacao é sobretudo efeito da seleção (o modelo não declara o que não recebe), não da abstenção do modelo. O detector é um regex ruidoso: na revisão manual só ~18 das frases são limitações admitidas pelos autores (precisão ≈ 30%, ADR 0002). Ressalva: as pistas de seleção e o regex de medição compartilham cinco termos; nas frases sem pista, as pistas não ajudam com 12k — o ganho real está nas limitações explícitas revisadas à mão (ADR 0002).

2. Prompt: duas versões e a comparação (4.2)

versão	técnicas	descrição
v_full	papel, delimitadores, few-shot (com caso null), abstenção	Versão de referência.
v_sem_fewshot	papel, delimitadores, abstenção	Difere da referência em uma técnica.

O que muda: v_full × v_sem_fewshot: few_shot: on → off

métrica	v_full	v_sem_fewshot
JSON válido de primeira	100%	100%
parse falhou (sem ficha)	0%	0%
null correto quando não há limitação	100%	100%
trecho encontrado (fidelidade)	95%	79%
página correta	84%	53%
vazamento de exemplos	11%	0%
fichas idênticas entre versões	0%	0%
tokens de entrada	73.614	57.198

O que a comparação mostrou: v_full vence por rate_fidelity: 0.947 (v_full) vs 0.789 (v_sem_fewshot); critérios anteriores empataram. Discordam em 101 campo(s): dados, evidencia.pagina, evidencia.trecho, limitacao, metodo, metrica, problema. Versão final: v_full. Trade-off: v_full tem fidelidade 95% × 79%, mas 11% das fichas copiam campos do exemplo (× 0% em v_sem_fewshot); o critério de vitória declarado não muda.

3. Modelo e temperatura (4.2-4.3)

Modelo: Qwen/Qwen2.5-3B-Instruct · Apple Silicon (MPS), float16. Qwen2.5-3B-Instruct cabe na T4 gratuita em meia precisão (~6 GB + contexto) e é o equilíbrio recomendado: o 1,5B erra demais nesta tarefa e o 7B exige 4 bits. Erros do modelo pequeno são matéria-prima da auditoria, não impedimento. Onde rodou de fato: Apple Silicon (MPS), float16, sem quantização (registrado no manifest de cada execução) — e não na T4 do Colab. A precisão declarada (fp16) é a mesma; reexecutar em CUDA pode mudar a saída gulosa em empates numéricos, e a auditoria seria refeita sobre as novas saídas. O notebook entregue reaproveita as saídas brutas de data/runs.

Temperatura: Extração é tarefa de fidelidade, não de criatividade: queremos a saída mais provável e reproduzível entre execuções (seed fixa). A verificação 4.4d mede o que muda com uma temperatura mais alta.

4. Auditoria: as quatro verificações (4.4)

a) Fidelidade. 1/19 trecho(s) inventado(s), ausente(s) do texto enviado: 08_Leka_2019 (cópia do exemplo few-shot do prompt). Página errada em 2/19 (11_Jarolim_2023: declarada 15, encontrada 16; D04_Jiao_2020: declarada 18, encontrada 15): trecho real, mas a ficha não é rastreável como declarada — BAIXA.

trecho encontrado: 18/19 (95%) · **página correta:** 16/19 · **exato / aproximado / sem ficha:** 17 / 2 / 0

Invenções convincentes detectadas — (1) 08_Leka_2019, execução semantic (principal): o modelo copiou do exemplo few-shot do prompt os campos dados, metodo, metrica e o trecho «Forecast accuracy is measured with the weighted mean absolute percentage error (WMAPE) over a 13-week horizon.», ausente do artigo. Detectado pela fidelidade, que compara o trecho com o texto enviado — do qual o exemplo não faz parte. (2) 06_Barnes_2016, execução hybrid (experimento): o campo limitacao «Os rótulos vêm de chargebacks, então fraudes nunca contestadas pelos clientes ficam fora da verdade de referê...» foi copiado do exemplo few-shot, com trecho de evidência correto — fidelidade e página passam. Só a comparação dos campos com os exemplos do prompt detecta. JSON válido de primeira: nenhuma checagem de formato os pegaria. Outros 5 caso(s) nas tabelas das verificações a) e e).

b) Estabilidade. 19/19 fichas idênticas nas duas execuções — esperado com decodificação gulosa e seed fixa. Por isso a variabilidade real do pipeline aparece no efeito da entrada (c) e da temperatura (d), não aqui.

pares comparados: 19 · **fichas idênticas:** 19/19 (100%) · **campos que mais mudam:** nenhum

c) Efeito da entrada. Defendemos semantic: semantic vence por maior taxa de página correta (0.842 vs 0.684). Experimento hybrid × semantic: comparação a três na seção 1. Sem gabarito manual não dá para separar abstenção correta de omissão; a heurística de vocabulário de limitação teve falsos positivos confirmados (título 'Scope, and Limitations'; parágrafo sobre limitações da IA generativa) e por isso não entra na regra.

estratégias: semantic × first_pages · **fichas idênticas:** 0/19 · **divergências substantivas:** 103 · **fidelidade:** semantic 95% · first_pages 95% · **campos que mais divergem:** problema 100%, metodo 95%, dados 89% · **limitacao null:** semantic 18/19 · first_pages 19/19

d) Efeito da temperatura. Pelo critério declarado (JSON válido, depois fidelidade), t=0,0 perde neste subconjunto: fidelidade 83% vs 100% em t=0,7. A diferença vem de: 08_Leka_2019 (vazamento do exemplo few-shot). Já a página correta, o critério que decidiu a 4.4c, favorece t=0,0: 5/6 vs 3/6; pela regra de confiança, t=0,7 geraria mais fichas BAIXA. Com n=6 artigos nada disso é conclusivo; mantemos t=0,0 pela página correta e porque a saída determinística deixa a estabilidade (b) sem ruído de amostragem, e reportamos o resultado como está. Subconjunto: os 6 primeiros artigos em ordem alfabética, fixados antes de rodar (não é amostra aleatória).

subconjunto: 6 artigos · **JSON válido de primeira:** t=0,0: 100% · t=0,7: 100% · **fidelidade:** t=0,0: 83% · t=0,7: 100% · **página correta:** t=0,0: 5/6 · t=0,7: 3/6 · **fichas idênticas:** 0/6

e) Vazamento de exemplos few-shot. Cópias do exemplo aparecem mesmo com exemplos em domínio propositalmente distante; a verificação compara cada campo com o campo homólogo dos exemplos (limiar 0,80).

semantic (principal): 2/19 (dados, metodo, metrica, evidencia.trecho) · **hybrid (experimento):** 2/19 (limitacao, evidencia.trecho) · **v_sem_fewshot:** 0/19

Regra de confiança (declarada): Regra de confiança v2 (aplicada automaticamente; o nível final é o MENOR entre os limites abaixo):

- BAIXA se a extração falhou (nenhum JSON válido segundo o esquema), ou o trecho de evidência não foi encontrado no texto enviado ao modelo (similaridade parcial_ratio normalizada < 0.90), ou o trecho foi encontrado numa página diferente da declarada em evidencia.pagina, ou algum campo textual (problema, dados, metodo, metrica, limitacao, evidencia.trecho) reproduz o campo homólogo de um exemplo few-shot do prompt (similaridade ≥ 0.80; trecho também contra o texto do exemplo), ou algum campo contém um termo de domínio exclusivo dos exemplos (fraude, chargeback, supermercados, vendas, WMAPE, suavização exponencial...) cujo equivalente em inglês não aparece no texto enviado — cópia do exemplo é invenção, mesmo quando o trecho passa na fidelidade, ou mais de 2 campos mudaram entre as duas repetições (mesma entrada).

- MEDIA se a evidência passou, mas entre 1 e 2 campos mudaram entre as repetições, ou limitacao é null numa estratégia de entrada e preenchida na outra (discordância categórica), ou se alguma comparação não pôde ser feita (ausente ou sem ficha válida do outro lado): o que não foi verificado não recebe ALTA.

- No máximo MEDIA se o campo limitacao veio preenchido mas o texto enviado não contém nenhum termo de limitação (limitation, shortcoming, drawback, caveat, future work, threats to validity...), sinal de limitação possivelmente inventada. O caso inverso (limitacao null com a palavra 'limitation' no contexto) NÃO rebaixa: a heurística teve falsos positivos (títulos de seção e uso genérico da palavra).

- ALTA somente se a evidência foi encontrada na página declarada e no máximo 0 campo(s) mudou(aram) entre repetições e não há discordância categórica entre estratégias.

- BAIXA também para as 8 fichas em que a revisão manual do grupo (leitura da ficha contra o artigo) encontrou um erro que as verificações automáticas não medem: sigla expandida com nome inventado, número ou tema ausente do texto enviado, trecho que não sustenta os campos (um título, uma tabela). A fidelidade prova que o trecho existe, não que os campos o seguem; o motivo lido fica registrado ficha a ficha e só rebaixa, nunca promove.

Campos comparados: problema, dados, metodo, metrica, limitacao, evidencia.trecho, evidencia.pagina; textos iguais após normalização tipográfica (NFKC, minúsculas, espaços, aspas e hífen).

Modo de comparação entre estratégias: categorical (v2) — entre estratégias só conta como mudança a discordância categórica em limitacao (null de um lado, texto do outro); paráfrase de texto livre e evidência de outra página não contam. Entre repetições (mesma entrada) a comparação continua exata.

Distribuição resultante: alta 9, média 1, baixa 9.

Calibração da regra — v1 estrita: alta 0/média 2/baixa 17; v2 categórica: alta 14/média 1/baixa 4; v2 + revisão manual (final): alta 9/média 1/baixa 9. A similaridade média dos campos de texto livre é 0,48 entre estratégias (paráfrase de entradas diferentes) e 1,00 entre repetições: comparar o texto exato entre estratégias mede redação, não confiabilidade. Por isso a regra final só conta discordância categórica entre estratégias (limitação declarada × null).

5. Fichas que não defenderíamos

arquivo	motivos
08_Leka_2019_Comparison_Flare_Forecasting_III_Systematic_Behaviors.pdf	campos dados, metodo, metrica, evidencia.trecho copiados do exemplo few-shot (similaridade 0.97–1.00); termos do exemplo few-shot ausentes do texto enviado em dados, metodo, metrica, evidencia.trecho: 'supermercados', 'vendas', 'promoções', 'feriados', 'WMAPE', 'suavização exponencial'; trecho não encontrado no texto enviado (score 0.47 < 0.90): possível trecho inventado
09_AsenioRamos_2023_ML_in_Solar_Physics.pdf	termos do exemplo few-shot ausentes do texto enviado em dados: 'supermercados'; revisão manual: o artigo é uma revisão (Living Reviews); a ficha descreve o trabalho de Bobra & Couvidat citado no trecho, e o '123' vem do rodapé da editora (p. 2)
11_Jarolim_2023_Coronal_Field_PINN.pdf	página errada: declarada p. 15, trecho localizado em p. 16; revisão manual: o trecho de evidência é o título do próprio artigo, vindo do rodapé 'Cite this article' (p. 16): um título não sustenta nenhum campo
14_Licata_Mehta_2022_UQ_DataDriven_Space_Weather.pdf	revisão manual: problema fala em 'densidade solar e geomagnética'; o artigo modela densidade termosférica (título, p. 1)
17a_Roy_2025_Surya_Foundation_Model_Heliophysics.pdf	revisão manual: metrica expande TSS/HSS como 'meio de tensão simétrica' (o artigo diz True Skill Statistic, p. 19); metodo cita um 'modelo de fusão de tempo' que não existe no artigo — provável eco do 'Temporal fusion transformer' do exemplo few-shot
D01_Li_2020_Predicting_Flares_Deep_CNN.pdf	revisão manual: metrica expande TSS/HSS como 'Score de Tendência de Sazonalidade' e 'Hidrometria de Sazonalidade'; o artigo define True Skill Statistic e Heidke Skill Score (p. 8) e o texto enviado só traz as siglas — expansão inventada
D02_Wang_2020_Predicting_Flares_ML_Solar_Cycle_Dependence.pdf	revisão manual: metodo diz 'LSTM de 20 camadas'; o artigo usa two-layer LSTM (p. 5)
D03_Sun_2022_Predicting_Flares_CNN_LSTM_Two_Solar_Cycles.pdf	revisão manual: dados diz '2010 a 2020; período e volume não informados' — contradição interna, com a segunda metade copiada do exemplo few-shot
D04_Jiao_2020_Flare_Intensity_Prediction_ML.pdf	página errada: declarada p. 18, trecho localizado em p. 15; revisão manual: dados é uma sequência de números copiada de uma tabela do apêndice (p. 26), sem fonte, período nem volume

As 5 fichas marcadas só por 'revisão manual' passaram em todas as verificações automáticas: trecho real, na página declarada, idêntico entre repetições. O erro está nos campos livres — siglas expandidas com nomes inventados, um número de camadas, o tema do artigo — que a fidelidade não olha: ela prova que o trecho existe, não que os campos o seguem. Foi a leitura da ficha contra o artigo que os encontrou, e por isso ALTA sem leitura não vale como garantia. Nas outras 9 fichas ALTA a leitura não achou erro desse tipo, mas não há gabarito: são as fichas que defenderíamos, não as que provamos corretas. A nossa invenção mais convincente não é 'supermercados' num artigo de física solar — é 'Score de Hidrometria de Sazonalidade' para HSS, plausível para quem não conhece a sigla.

6. Custo (4.5)

Premissa: US\$ 3.00 por 1M tokens de entrada e US\$ 15.00 por 1M tokens de saída (fonte: Tabela pública Anthropic, Claude Sonnet 4.5, consultada em 2026-09).

cenário	chamadas	tokens entrada	tokens saída	US\$
TOTAL real (todas as execuções)	117	480.287	29.223	1,8792
ingênuo (artigo inteiro, mesmas chamadas)	117	2.612.853	29.223	8,2769

Razão ingênuo/real: a alternativa ingênua custa 4,40× a real.

Tokens de entrada: a alternativa ingênua envia 5.4× mais. O total real inclui tudo o que foi enviado: repetição de estabilidade, outra estratégia, outra temperatura, outra versão do prompt e os experimentos de seleção (execuções hybrid). Execução 20260923-155849_hybrid_v_full_t0.0_rep2 (Interrompida pelo grupo em 16/19 após a estratégia híbrida ser descartada pelo critério da 4.4c; os 16 registros contam no custo (foram enviados).).

7. O que faríamos diferente com mais uma semana

- Uma segunda passagem dedicada só a limitacao, sobre as janelas de pista de limitação (a entrada já as traz; o modelo de 3B não as usa na ficha completa).
- Modelo maior — Qwen2.5-7B em 4 bits ou um modelo por API — nas mesmas 19 fichas.
- O prompt já diz "não copie o conteúdo dos exemplos" e isso não impediu o vazamento; testar exemplos-esqueleto (campos com marcadores em vez de valores) e medir se o vazamento some sem perder a fidelidade que o few-shot trouxe.
- Gabarito manual de limitacao em 5 artigos, para separar abstenção de omissão.

8. Declaração de uso de IA

Usamos assistentes de IA (Claude) para gerar a maior parte do código do pacote ficha, dos testes e da documentação, e para revisar textos, a partir de decisões de projeto do grupo registradas nos ADRs. O grupo revisou o código e sabe explicar cada linha. Os números vêm das execuções gravadas em data/runs; as conclusões e a revisão manual das fichas são do grupo.